刁海康

15201736882 | diaohaikang@alumni.pku.edu.cn | 北京
1997-12 | 男
个人网站：haikangdiao.github.io



教育经历

北京大学 2022年09月 - 2026年06月
集成电路科学与技术 博士 集成电路学院 北京
- 导师：王源教授（北京邮电大学副校长）、唐希源研究员（北大博雅青年学者）
- 研究方向：**高效 AI 芯片与系统设计**、数字存算一体、模型压缩与硬件加速系统设计
- **排名：1/90（2024-2025）**；博士生国家奖学金、北京市优秀毕业生

复旦大学 2019年09月 - 2022年06月
电路与系统 硕士 信息科学与工程学院 上海
- 导师：陈炜教授；研究方向：轻量化睡姿感知软硬件系统、**模型压缩与加速算法**

复旦大学 2015年09月 - 2019年06月
电子信息科学与技术 本科 信息科学与工程学院 上海
- 免试直研至复旦大学电子工程系电路与系统硕士研究生

工作经历

华为 计算产品线 2026年07月 - 至今
高级研究员 北京
- 入选 **Huawei Top Minds Program**；从事**昇腾系统架构设计与 AI 基础设施设计**，聚焦面向 AI 计算系统的软硬件协同优化。

科研经历

北京大学 PRIME 课题组 2022年07月 - 2026年06月
围绕端侧高效 AI 芯片与系统设计，从**电路、系统、工具链**三个层面开展研究。主导设计 **6 款**基于数字 SRAM/eDRAM 存算的 AI 加速器，**其中 5 颗已流片**；负责 CNN/LLM 算法压缩与部署（量化、稀疏、算子近似）、数字与模拟前后端及数模混合设计。成果发表于 JSSC、TCAS-I、TCAS-AI、CICC、ICCAD、DATE 等期刊和会议。

1. 电路级：基于算法近似的数字存算一体芯片
- **近似计算 Macro：**以无乘法算子近似乘法运算，设计专用动态逻辑比较器电路，实现约 3 倍功耗优化。
- **浮点数字存算一体：**设计一步计算浮点数据流、定制化并行比较器及无损结构化稀疏算法与架构，支持片上微调，提升复杂端侧环境下的模型推理精度；CICC 2024 工作实现 **128 TFLOPS/W**。
- **混合精度量化（Adder-DCIM）：**构建融合算子重构、无损稀疏和混合精度量化的模型压缩框架；设计混合精度计算核与并行同步架构，实现 **4-5 倍性能提升**。

2. 系统级：软硬件协同设计 CIM 加速器
- **访存优化与多算子适配（AdapCIM）：**设计自适应数据流，减少片外 DRAM 读写，实现约 2.6 倍端到端功耗优化；以行/列共享电路支持多种卷积算子，结合卷积核级稀疏加速，实现 **28 nm、73 TOPS/W**，获 TCAS-AI 2026 接收。
- **端侧 LLM 的 Prefill-Decode 统一加速（UniPD）：**设计动态 token 切分、全定点编码与计算架构，以及基于 head 切分的 QKVRA 融合数据流，提升带宽利用率；采用高密度、低功耗、免刷新的 eDRAM-CIM 提升片上计算能效，成果发表于 **TCAS-I 2026**。

3. 工具链级：基于设计空间探索的 CIM 自动化工具
- **数字 CIM 编译器（SEGA-DCIM）：**提出可综合的 DCIM 框架模板和开销模型，采用遗传算法开展设计空间探索，实现定制化 DCIM 架构与版图生成，支持多精度设计。
- **eDRAM CIM 设计空间探索：**结合 IGZO 新器件与 3D 封装，开展面向不同任务的 cell-阵列-架构多层次探索，为硬件设计提供指导。

复旦大学 智慧医疗电子中心课题组（CIME） 2019年02月 - 2022年06月
- 设计基于压力感应床垫的智能睡姿识别系统，负责硬件、算法、数据采集实验与分析全流程；成果发表于 IEEE TBioCAS。
- 提出基于频率通道选择的模型压缩算法，学习各通道的分类敏感度并精简输入，实现**超过 100 倍模型压缩**，部署于嵌入式处理器进行实时睡姿分类；成果发表于 IEEE IoTJ。

学术服务：担任 JSSC、SSCL、TCAS-AI、TNNSRE、ISCAS 审稿人。

实习经历

知存科技 2025年05月 - 2026年02月

架构实习生 架构部 北京

- 设计面向 eDRAM CIM 的设计空间探索工具，结合 IGZO 等新器件开展 cell-阵列-架构多层次探索，进行硬件与系统建模分析。
- 面向训推一体 demo，与算法和电路团队协作设计 eDRAM CIM 芯片架构、模型量化算法与误差补偿方案。

华为诺亚方舟实验室 2021年07月 - 2021年12月

AI 算法实习生 计算机视觉实验室 北京

- 利用聚类分组、权重截断实现加法神经网络低精度量化，**4 bit 量化精度损失约 1%**；以加法算子替代乘法算子实现 Adder-MLP，并结合知识蒸馏提升精度。

OPPO AI 研究院 2021年03月 - 2021年06月

模型压缩与部署实习生 智能感知中心 上海

- 基于 MobileNet、EfficientNet 开展量化感知训练与训练后量化；使用高通 SNPE、阿里巴巴 MNN 完成边缘端模型量化、部署及性能测试。

荣誉奖项

北京市优秀毕业生（前 5%）、北京大学优秀毕业生（前 15%）	2026
北京大学博士生国家奖学金（前 5%）	2025
院长奖学金卓越奖（前 5%）	2025
北京大学优秀科研奖	2023、2024
复旦大学优秀毕业生	2022
一等奖学金	2020
中国大学生服务外包创新创业大赛全国二等奖（前 1%）	2019
复旦大学信息科学与工程学院十佳学生	2019

一作论文发表（含共同一作）

1. Suyu Wang, **Haikang Diao***, et al., "A Refresh-Free eDRAM-CIM Accelerator With UniPD Design-Space Exploration for Unified Prefill-Decoding LLM Inference," in IEEE Transactions on Circuits and Systems I: Regular Papers (**TCAS-I**), 2026.
2. **Haikang Diao** et al., "AdapCIM: A 28nm 73TOPS/W Adaptive Stationary Digital CIM Accelerator with Inter-Column/Row Sharing and Kernel-Wise Sparsity," in IEEE Transactions on Circuits and Systems for Artificial Intelligence (**TCAS-AI**), 2026.
3. **Haikang Diao** et al., "Adder-DCIM: A Parallel Bit-Flexible Digital CIM Joint Model Compression Framework for AdderNet Inference," in IEEE/ACM International Conference on Computer-Aided Design (**ICCAD**), 2025.
4. **Haikang Diao** et al., "A Computing-In-Memory Engine Supporting One-Shot Floating-Point NN Inference and On-Device Fine-Tuning for Edge AI," in **IEEE Journal of Solid-State Circuits (JSSC)**, 2025.
5. **Haikang Diao***, Haoyi Zhang*, et al., "SEGA-DCIM: Design Space Exploration-Guided Automatic Digital CIM Compiler with Multiple Precision Support," in Design, Automation and Test in Europe Conference (**DATE**), 2025.
6. **Haikang Diao** et al., "A Multiply-Less Approximate SRAM Compute-In-Memory Macro for Neural-Network Inference," in **IEEE Journal of Solid-State Circuits (JSSC)**, 2024.
7. **Haikang Diao** et al., "A 28nm 128TFLOPS/W Computing-In-Memory Engine Supporting One-Shot Floating-Point NN Inference and On-Device Fine-Tuning for Edge AI," in IEEE Custom Integrated Circuits Conference (**CICC**), 2024.
8. **Haikang Diao** et al., "Real-time and Cost-effective Smart Mat System based on Frequency Channel Selection for Sleep Posture Recognition in IoMT," in IEEE Internet of Things Journal (**IoT-J**), 2022.
9. **Haikang Diao** et al., "Edge-Computing System based on Smart Mat for Sleep Posture Recognition in IoMT," in EAI International Conference on Wireless Mobile Communication and Healthcare (**MobiHealth**), 2021.
10. **Haikang Diao** et al., "Deep Residual Networks for Sleep Posture Recognition With Unobtrusive Miniature Scale Smart Mat System," in IEEE Transactions on Biomedical Circuits and Systems (**TBioCAS**), 2021.
11. **Haikang Diao** et al., "Unobtrusive Smart Mat System for Sleep Posture Recognition," in IEEE International Symposium on Circuits and Systems (**ISCAS**), 2021.

* 表示共同第一作者。